

产品需求文档（PRD）：大宗商品与宏观经济高纯度数据采集管道

属性	内容
文档版本	v2.6 (Production Complete)
产品名称	大宗商品与宏观经济高纯度数据采集管道 (Commodity Intel Pipeline)
核心目标	打造具备防脏数据穿透、唯一性约束与时区感知的企业级高纯度 ETL 面板数据采集与智能推送引擎
数据下游	飞书多维表格 (Fact Table)、飞书机器人 (Interactive Card)、计量分析模型 (Stata/Python Panel Data)

一、 产品背景与业务痛点 (Background & Pain Points)

在针对大宗商品基本面、地缘政治规制与宏观经济进行数据搜集与计量分析时，传统的自动化抓取脚本面临四大致命痛点：

- 数据笛卡尔积膨胀 (Data Explosion)**：以信息点为外层循环会导致同一篇新闻被不同的研究课题反复提取、多次写入，严重破坏面板数据 (Panel Data) 的样本唯一性。
- 泛新闻噪音穿透 (Noise Contamination)**：RSS 源中混入了大量的体育赛事（如世界杯）、个人理财、公司八卦等噪音，强行写入会导致数据信噪比骤降。
- 外媒长句英文穿透**：当 LLM 解析波动或接口异常时，英文原文直接落库，影响多维表格的

可读性与规范性。

4. **网络 I/O 冗余与 API 限流 (Rate Limiting)**：频繁、重复地向官方智库或媒体接口发起网络请求，极易触发 IP 封禁，破坏时间序列的连续性。

二、系统架构与五重提纯漏斗 (System Architecture)

系统抛弃了传统的“以课题/信息点为中心”的盲目轮询，全盘重构为“以文章/URL 为中心 (Article-Centric)”的五重漏斗提纯管道：

[源头 RSS Feeds (FT, EIA, Mining, Hellenic...)]

|

▼ **【漏斗 1：内存级全局请求缓存 (Global Feed Cache)】**

[解析条目 (Title, Link, Desc)]

|

▼ **【漏斗 2：物理年份与 24h 时区窗口 (_CUTOFF = TODAY - 1 day)】**

[正文完整补全 (Trafilatura)]

|

▼ **【漏斗 3：内存级局域打标与合并 (Core Matching & Merging)】**

[大模型二分类与结构化提炼 (DeepSeek Gateway + 中文强制兜底)]

|

▼ **【漏斗 4：黑白名单双重硬阻断 (Relevance Gate: is_target_related)】**

[带指纹的结构化数据 JSON]

|

▼ **【漏斗 5：写入前双重指纹校验 (Pre-Write Duplicate Guard)】**

[飞书多维表格 (Feishu Fact Table) 唯一落库]

三、核心流转节点与技术规则 (Detailed Specifications)

1. 内存级全局请求缓存 (Global Feed Cache)

- **设计逻辑**：建立全局字典 `_RSS_FEED_CACHE`。同一进程内，相同的 `feed_url` 仅发起**唯一一次**网络 HTTP 请求。
- **价值**：避免重复拉取同一官方源，降低 80% 以上的网络 I/O 消耗，彻底规避 API 限流与 IP 封禁风险。

2. 时区感知与物理年份漏斗 (Timezone-Aware & Year Filter)

- **滑动窗口**：采用适应国际时差的 24 小时滑动窗口 (`_CUTOFF = TODAY - 1 day`)，兼顾数据新鲜度与海外夜间新闻的召回率（官方月报保留 30 天宽窗口 `_CUTOFF_30`）。
- **年份硬拦截**：在 RSS 解析层，直接通过正则 `_HIST_YEAR_RE` 检验标题和 URL。若明确包含历史年份（如 2025、2024 等），在正文抓取前**物理丢弃**，不浪费后续算力。

3. 相关性网关与二分类拦截器 (Relevance Gateway)

在发送给 DeepSeek 的 JSON Schema 中置入强制二分类与双重黑白名单约束：

- **7 类无条件黑名单**：体育赛事（世界杯/NBA 等）、个人理财、娱乐八卦、纯科技消费品发布、地方民生新闻、纯公司治理八卦、宗教文化旅游。
- **6 类正向准入白名单**：大宗商品供需/价格/库存、宏观经济数据传导、地缘政治供应链冲击、航运运价与通道动态、监管政策（关税/储备/CBAM）、交易所期货结构。
- **断路器逻辑**：若 `is_target_related` 为 `false`，LLM 必须填写 `rejection_reason` 并将其他字段置为 `null`；代码层捕获后返回哨兵值 `__NOT_RELEVANT__`，物理阻断落库。

4. 强制中文与异常降维兜底 (Mandatory Chinese Summary)

- **Prompt 铁律**：强制要求 `analytical_summary` 及所有输出字段 100% 使用专业简洁的中文表达，严禁保留英文原文长句。
- **二次兜底机制 (`_deepseek_fallback_zh`)**：若 `summarize_v2` 触发解析异常或提炼失败，系统启动二次极简请求，将英文内容压缩为 ≤ 150 字的中文商业摘要，保证落库文本 100% 中文化。

5. 写入前双重指纹校验 (Pre-Write Duplicate Guard)

- **URL 精确指纹 (`existing_urls`)**：落库前调用 `get_today_records` 比对当日表格中的来源

链接，若碰撞成功直接阻断。

- **摘要内容指纹 (existing_fingerprints)**： 比对摘要前 50 字的特征码。若不同媒体通稿报道同一核心事件，触发内容雷同阻断，实现系统**绝对幂等性 (Idempotency)**。

四、 飞书多维表格业务数据字典 (Data Dictionary)

彻底删除废弃字段，飞书多维表格事实表 (Fact Table) 的标准化字段映射如下：

字段名称 (Field Name)	字段类型 (Type)	约束条件 (Constraint)	业务生成逻辑与学术/商业价值 (Extraction & Design Logic)
采集时间	毫秒时间戳	必填	系统运行时间戳 (TODAY_MS)，用于面板数据的时间序列对齐。
一级分类	单选/文本	必填	继承自课题配置的宏观领域分类（如：市场基本面、宏观政策）。
二级信息点	文本	必填	匹配到的 1~N 个研究课题名称（多课题命中时自动逗号拼接，消除重复数据）。

研究核心	文本	可空	对应的课题研究核心定义前 300 字上下文。
标题	文本	必填	LLM 提取的 商品品类/主题 + 最新动态（控制在 40 字以内）。
摘要	多行文本	必填	格式化高密数据洞察： 【报告时间】+ 商品品类 + 关键量化指标 + 期限结构/政策状态 + 100% 中文高浓度传导逻辑。
来源链接	链接 (URL)	主键 (Primary Key)	全局绝对唯一，用于触发 Write-Guard 指纹去重校验，实现绝对幂等性。
来源网站名称	文本	必填	域名自动映射显示名称（如：Hellenic Shipping News, FT, EIA, Mining.com）。

五、 消息推送与交互卡片规范 (Daily Report & Card

Schema)

1. 触发与调度机制 (Trigger & Schedule)

- **静默触发时间**：每日清晨 **05:00** (Cron Schedule) 。避开高频时段，为 24h 增量窗口的数据拉取、LLM 提炼与指纹去重预留缓冲。
- **推送时间**：每日 **05:15 ~ 05:30**。数据采集与清洗完成且有新增写入记录 (written > 0) 后，自动触发 reporter.py 向飞书群投递。
- **空数据守卫 (Skip Push)** ：若当日无新增数据 (written == 0) ，系统触发 [Skip Push] 逻辑，静默终止推送，绝对不向用户投递空卡片。

2. 飞书互动卡片结构规范 (Interactive Card Schema)

卡片严格按以下层次进行渲染：

卡片模块 (Block)	元素组件 (Component)	内容规范与渲染逻辑 (Formatting & Schema Rules)
Header 头部	蓝色背景 Header	标题格式： 大宗商品与宏观每日快报 · YYYY 年 MM 月 DD 日
Top Dashboard	AI 看点总览	1. 统计行： 今日共采集 {total} 条高纯度洞察 2. AI 看点 (Executive

		Summary)：提取前 8 条记录的摘要，调用 DeepSeek 提炼生成 ≤100 字的 今日核心看点
Grouped Items	分组精选展示	1. 分类标题：按 一级分类 分组（如： 市场基本面、宏观政策） 2. 展示上限：每个分类最多精选展示 3 条 3. 单条明细格式： [[level2]] {title} • 摘要：{short_summary} [查看源网页]({source_url}) 4. 折叠提示：若某分类 > 3 条，末尾标注 *...还有 {N} 条高价值数据，详见多维表格*

Footer Action	主行动点按钮	放置跳转 Button 查看飞书 多维完整面板，点击可直接 拉起浏览器并精准跳转至 Bitable 多维表格页面。

六、 验收测试结果与量化表现 (Acceptance Metrics)

根据实际测试跑批验证，本管道展现出如下工程指标：

- 1. **去重与降维效果**：原本 130 条重复写入的数据物理收敛为 48 条绝对独立的高价值信息，去重率达 **63%**，彻底解决样本重叠问题。
- 2. **信噪比与防穿透表现**：100% 成功阻断“世界杯财务”、“前学生免费理发”等非目标领域新闻。
- 3. **幂等性验证**：多次重复触发 fetch_data.py，后续运行触发 [Write-Guard] 全量阻断，新增写入数为 0，系统稳定性达到生产级要求。
- 4. **语言纯净度**：跨国 RSS 数据入库摘要 100% 实现专业中文转化，长句英文穿透率降为 **0%**。